

Universidad de El Salvador

Facultad de Ingeniería y Arquitectura

Escuela de Sistemas Informáticos

Curso de Especialización en Machine Learning

Laboratorio 2

Question Answering y Retrieval-Augmented Generation
sobre documentación académica de la Universidad de El Salvador

Informe técnico final

Estudiantes: Josias Abner Rivas Fuentes
Elmer Edenilson Rosales Molina

Catedrático: Vladimir Dias

Fecha: 14 de agosto de 2026

Resumen

Este laboratorio estudia Question Answering (QA) extractivo en español y su integración con recuperación semántica sobre normativa de la Universidad de El Salvador. El desarrollo parte de contextos breves, compara tres modelos BETO, evalúa seis configuraciones de fragmentación y construye un índice FAISS con embeddings normalizados. La configuración monodocumento final combina BETO-SQAC, MPNet multilingüe, chunks de 800 caracteres, solapamiento cero y Top-10. Sobre el documento de 62 páginas y diez preguntas obtuvo Recall@10 y QA Accuracy de 60 %. La extensión multidocumento conserva esa configuración y amplía el corpus a nueve PDF, 199 páginas y 765 chunks. En ella, Document Recall@10 fue 93.75 %, Chunk Recall@10 56.25 % y QA Accuracy sobre preguntas respondibles 25 %. La brecha entre etapas demuestra que seleccionar el documento no garantiza localizar la evidencia ni extraer el span correcto. Se preservan los resultados negativos, la procedencia de cada fragmento y un análisis de errores por etapa.

Palabras clave: Question Answering, QA extractivo, BETO, RAG, embeddings, MPNet, FAISS, recuperación semántica, chunking.

Índice

1. Introducción	1
2. Objetivos	1
2.1. Objetivo general	1
2.2. Objetivos específicos	1
3. Fundamentos teóricos	2
3.1. Transformer, BERT y BETO	2
3.2. Score y exactitud	2
3.3. Chunking y overlap	2
3.4. Embeddings, coseno y FAISS	2
3.5. Recall@K y MRR	3
4. Datos y preparación documental	3
4.1. Documento obligatorio	3
4.2. Corpus multidocumento	4
5. Metodología y arquitectura	4

5.1. Flujo monodocumento	4
5.2. Flujo multidocumento	4
5.3. Criterios de selección	5
6. Comparación de modelos QA	5
7. Fragmentación del documento	5
8. Embeddings, FAISS y Top-K	6
9. Baseline exhaustivo frente a RAG	7
10. Selección de embeddings y tamaño de base	7
10.1. MiniLM frente a MPNet	7
10.2. Tamaño de la base vectorial	9
11. RAG monodocumento final	9
12. Extensión RAG multidocumento	10
12.1. Diseño	10
12.2. Resultados de recuperación	10
12.3. Respuesta y abstención	10
13. Análisis de errores	12
13.1. Taxonomía	12
14. Discusión	13
14.1. Monodocumento frente a multidocumento	13
14.2. Decisiones técnicas	13
15. Limitaciones	14
16. Trabajo futuro	14
17. Reproducibilidad	15
18. Conclusiones	15

Referencias	17
A. Trazabilidad de artefactos	18
B. Resumen de preguntas documentales	18
C. Validación final	19

Índice de figuras

1. Score y tiempo de los modelos en el contexto inicial. Fuente: resultados ejecutados del proyecto.	6
2. Accuracy histórica del RAG MiniLM para los cuatro valores de K.	7
3. Tiempo registrado del baseline y RAG; las fases usaron dispositivos distintos.	8
4. Recall@10 con MiniLM y MPNet sobre los mismos 217 chunks.	8
5. Recall@10 según el tamaño controlado de la base.	9
6. Document Recall@K de la extensión multidocumento.	11
7. Chunk Recall@K: recuperación de página y evidencia anotadas.	11
8. Comparación descriptiva; los conjuntos de preguntas son distintos.	13

Índice de cuadros

1. Propiedades verificadas del documento obligatorio.	3
2. Alcance de los dos corpus ejecutados.	4
3. Comparación controlada y selección del extractor.	5
4. Resultados de chunking y solapamiento.	6
5. Evaluación histórica de Top-K con MiniLM.	6
6. Comparación histórica del barrido exhaustivo y RAG MiniLM.	7
7. Comparación controlada de embeddings.	8
8. Efecto de distractores con MPNet y Top-10.	9
9. Configuración final del laboratorio obligatorio.	10
10. Recuperación multidocumento por nivel y K.	10
11. Errores observados en la extensión.	12

12.	Comparación descriptiva de los dos experimentos.	13
13.	Relación entre entregables y evidencia.	18
14.	Preguntas del experimento monodocumento.	18
15.	Estado de los componentes de entrega.	19

1. Introducción

Un sistema de Question Answering recibe una pregunta y un contexto, y busca producir una respuesta sustentada en ese texto. En la variante extractiva, el modelo predice las posiciones inicial y final de un span; no redacta una respuesta nueva. BERT formalizó una arquitectura bidireccional de encoder que puede ajustarse para esta tarea [2], mientras BETO adaptó esa familia al español [3].

La aplicación directa de QA a documentos extensos presenta dos problemas. Los modelos evaluados admiten como máximo 512 tokens entre pregunta y contexto, y la selección del mayor score entre cientos de fragmentos favorece falsos positivos de alta confianza. El laboratorio aborda ambos problemas de manera incremental: fragmenta el PDF, compara el coste de un barrido exhaustivo, representa los chunks mediante embeddings y recupera únicamente los candidatos mejor posicionados antes de ejecutar BETO-SQAC.

La denominación RAG se conserva por continuidad con el proyecto y con el paradigma de recuperación aumentada [7]; sin embargo, la etapa de respuesta implementada es extractiva, no generativa. Esta precisión permite interpretar correctamente el sistema y sus limitaciones.

2. Objetivos

2.1. Objetivo general

Diseñar y evaluar un sistema de preguntas y respuestas extractivo en español sobre contextos breves y documentos institucionales extensos, incorporando recuperación semántica y analizando por separado calidad de respuesta, recuperación, procedencia y coste computacional.

2.2. Objetivos específicos

- Comparar modelos QA en español bajo preguntas y criterios comunes.
- Extraer y fragmentar un PDF real sin perder offsets ni páginas.
- Evaluar tamaño de chunk, solapamiento, Top-K y modelo de embeddings.
- Construir una base vectorial exacta con FAISS.
- Distinguir score QA, Accuracy, Recall@K y MRR.
- Conservar el laboratorio monodocumento como experimento independiente.
- Extender el pipeline a varios PDF con metadata documental completa.
- Clasificar errores sin cambiar preguntas, etiquetas o respuestas.

3. Fundamentos teóricos

3.1. Transformer, BERT y BETO

El Transformer reemplaza recurrencia y convoluciones por mecanismos de atención que relacionan los tokens de una secuencia [1]. BERT usa un encoder bidireccional preentrenado y puede ajustarse para estimar logits de inicio y fin de respuesta [2]. BETO es un modelo BERT preentrenado específicamente con texto en español [3].

Los tres checkpoints evaluados pertenecen a esta familia. No se entrenaron modelos desde cero ni se modificaron sus pesos; se ejecutó inferencia mediante la interfaz de QA extractivo de Transformers [8]. El modelo final es el checkpoint BETO-SQAC publicado por MMG [9].

3.2. Score y exactitud

El score del pipeline mide la confianza relativa en un span dentro del contexto recibido. No comprueba que el contexto sea pertinente y no equivale a Accuracy. En el proyecto se etiquetaron scores altos desde 0.75, medios desde 0.40 y bajos por debajo de 0.40. Estos umbrales son operativos y no universales.

Para N preguntas, la exactitud es

$$\text{Accuracy} = \frac{\text{respuestas correctas}}{N}. \quad (1)$$

La evaluación normaliza mayúsculas, diacríticos y signos; acepta igualdad, presencia de la respuesta dentro de un span mayor y variantes explícitamente declaradas. Las revisiones permanecen identificadas.

3.3. Chunking y overlap

El documento se divide en ventanas de longitud L caracteres. Si el solapamiento es O , el desplazamiento entre inicios consecutivos es

$$P = L - O. \quad (2)$$

El overlap puede proteger evidencia cercana a un corte, pero aumenta duplicación, número de chunks e inferencias. Su utilidad debe evaluarse en vez de asumirse.

3.4. Embeddings, coseno y FAISS

Sentence-BERT produce representaciones densas adecuadas para similitud semántica [4]. El modelo final usa una variante multilingüe basada en MPNet [5, 10]. Dados dos vectores

$\mathbf{a}$ y $\mathbf{b}$, la similitud coseno es

$$\cos(\theta) = \frac{\mathbf{a}^\top \mathbf{b}}{\|\mathbf{a}\|_2 \|\mathbf{b}\|_2}. \quad (3)$$

Con normalización L2, el producto interno coincide con el coseno:

$$\hat{\mathbf{a}}^\top \hat{\mathbf{b}} = \cos(\hat{\mathbf{a}}, \hat{\mathbf{b}}). \quad (4)$$

Por ello se usó FAISS `IndexFlatIP`, un índice exacto que conserva la interpretabilidad del ranking [6]. FAISS recupera contexto; no genera ni evalúa la respuesta.

3.5. Recall@K y MRR

Recall@K mide la proporción de preguntas cuya evidencia aparece entre los K primeros candidatos:

$$\text{Recall@K} = \frac{\text{preguntas con evidencia en Top-K}}{\text{preguntas evaluables}}. \quad (5)$$

El rango recíproco medio resume cuán pronto aparece el primer resultado relevante:

$$\text{MRR} = \frac{1}{N} \sum_{i=1}^N \frac{1}{r_i}, \quad (6)$$

donde el término vale cero si la evidencia no aparece. En la extensión se calculan rangos distintos para documento y chunk.

4. Datos y preparación documental

4.1. Documento obligatorio

La fuente de la parte obligatoria es el *Reglamento de la Gestión Académico-Administrativa de la Universidad de El Salvador* [12]. PyMuPDF extrajo el texto página por página [11]. No se aplicó OCR porque todas las páginas contenían texto.

Cuadro 1: Propiedades verificadas del documento obligatorio.

Propiedad	Valor
Páginas	62
Caracteres crudos	177 390
Caracteres después de limpieza	173 419
Palabras aproximadas	26 119
Páginas con texto	62
Tamaño del PDF	497 732 bytes

La limpieza eliminó guiones blandos, recompuso palabras separadas por salto de línea y normalizó espacios. No resumió artículos ni corrigió el contenido. La metadata conservó página, offsets y texto.

4.2. Corpus multidocumento

La extensión añade ocho reglamentos al PDF original sin concatenarlos. Cada documento se extrae y fragmenta por separado; la concatenación ocurre solo a nivel de la lista de metadata y de la matriz vectorial.

Cuadro 2: Alcance de los dos corpus ejecutados.

Propiedad	Monodocumento	Multidocumento
Documentos	1	9
Páginas	62	199
Palabras aproximadas	26 119	94 263
Chunks/vectores	217	765
Dimensión final	768	768

Cada chunk multidocumento conserva `documento`, `pagina`, `chunk_id`, identificador global, posición vectorial y `texto`. La validación exige correspondencia uno a uno entre `vector_posicion`, metadata e índice FAISS.

5. Metodología y arquitectura

5.1. Flujo monodocumento

```
documento_fuente.pdf
-> extracción y limpieza
-> chunking 800/0
-> embeddings MPNet normalizados
-> FAISS IndexFlatIP, Top-10
-> BETO-SQAC
-> respuesta y evaluación
```

Las diez preguntas documentales se anotaron con respuesta, artículo, página y evidencia. El laboratorio no cambió preguntas ni respuestas esperadas para mejorar resultados.

5.2. Flujo multidocumento

```
pregunta
```

- > MPNet
- > FAISS Top-10
- > documento + página + chunk
- > BETO-SQAC
- > respuesta + score + fuente

Las 18 preguntas incluyen 16 respondibles distribuidas entre los nueve PDF y dos sin respuesta. Estas últimas no participan en Recall o MRR, pero sí en la evaluación de abstención.

5.3. Criterios de selección

Las decisiones priorizaron respuestas correctas, recuperación y trazabilidad antes que score o diferencias marginales de tiempo. Los tiempos proceden de una ejecución por configuración. La semilla 42 controla la construcción anidada de bases con distractores, pero no hace deterministas las mediciones.

6. Comparación de modelos QA

Se evaluaron tres checkpoints con cinco preguntas en cada uno de tres contextos: UES, bases de datos y Wikipedia adaptada. La comparación controlada final consta de 45 inferencias.

Cuadro 3: Comparación controlada y selección del extractor.

Modelo	Correctas	Accuracy	Score medio	Tiempo medio (s)
BETO-SQuAD2 (mrm8488)	13/15	86.67 %	0.541198	0.1215
BETO-SQuAD2 (MMG)	13/15	86.67 %	0.424900	0.1132
BETO-SQAC (MMG)	15/15	100 %	0.691953	0.1154

BETO-SQAC fue el único modelo con 15/15 y se seleccionó como extractor. La Figura 1 corresponde al contexto inicial; apoya la comparación de score y tiempo, pero no sustituye el agregado de la Tabla 3.

El archivo `results/comparacion_modelos.csv` conserva además un benchmark histórico de 60 inferencias. La selección 13/15, 13/15 y 15/15 se sustenta en `results/resultados_qa.csv`; ambos conjuntos se conservan y no se mezclan.

7. Fragmentación del documento

Se evaluaron seis configuraciones, expresadas como tamaño/overlap en caracteres.




Figura 1: Score y tiempo de los modelos en el contexto inicial. Fuente: resultados ejecutados del proyecto.

Cuadro 4: Resultados de chunking y solapamiento.

Config.	Chunks	Correctas	Accuracy	Score medio	Tiempo (s)
300/0	579	3/10	30 %	0.935121	288.147
300/50	694	4/10	40 %	0.915775	350.798
500/0	347	3/10	30 %	0.917160	223.805
500/100	434	4/10	40 %	0.938941	325.274
800/0	217	4/10	40 %	0.942767	236.143
800/150	267	4/10	40 %	0.898146	282.039

El overlap añadió un acierto en 300/50 y 500/100, pero no en 800/150; siempre aumentó chunks y tiempo. Entre las configuraciones con 4/10, 800/0 tuvo la base más pequeña, el menor tiempo y el mayor score medio. Se seleccionó como mejor compromiso del conjunto evaluado, no como valor universal.

8. Embeddings, FAISS y Top-K

El primer RAG usó MiniLM multilingüe, 217 vectores de 384 dimensiones y los mismos chunks 800/0. Se evaluaron $K = 1, 3, 5, 10$ sin reconstruir el índice.

Cuadro 5: Evaluación histórica de Top-K con MiniLM.

K	Correctas	Accuracy	Recall@K	Score QA	Tiempo (s)
1	1/10	10 %	10 %	0.269381	0.189
3	3/10	30 %	30 %	0.640720	0.508
5	3/10	30 %	30 %	0.702736	0.721
10	4/10	40 %	40 %	0.836432	1.408

Top-10 fue el único valor con cuatro respuestas correctas y se mantuvo en las fases poste-

riores. La Figura 2 muestra el aumento de Accuracy; el coste creció porque BETO recibió más contextos.




Figura 2: Accuracy histórica del RAG MiniLM para los cuatro valores de K.

9. Baseline exhaustivo frente a RAG

Cuadro 6: Comparación histórica del barrido exhaustivo y RAG MiniLM.

Método	Correctas	Accuracy	Tiempo (s)	Inferencias QA
QA exhaustivo 800/0	4/10	40 %	236.143	2 170
RAG MiniLM Top-10	4/10	40 %	1.408	100

El RAG redujo las inferencias en 95.4 % sin cambiar la Accuracy histórica. El speedup registrado fue 167.75×, pero el baseline quedó en CPU y el RAG posterior en CUDA. Por ello la Figura 3 se interpreta como tiempo observado, no como aislamiento causal del aporte de FAISS.

10. Selección de embeddings y tamaño de base

10.1. MiniLM frente a MPNet

MPNet elevó Recall@10 y Accuracy en 20 puntos porcentuales. Sus embeddings tardaron 3.06 veces más, pero el tiempo de consulta fue similar. La mejora se atribuye al modelo completo bajo condiciones fijas, no únicamente a su dimensión.




Figura 3: Tiempo registrado del baseline y RAG; las fases usaron dispositivos distintos.

Cuadro 7: Comparación controlada de embeddings.

Modelo	Dim.	Recall@10	Accuracy	Embeddings (s)	Consultas (s)
MiniLM	384	40 %	40 %	0.536	1.432
MPNet	768	60 %	60 %	1.642	1.420




Figura 4: Recall@10 con MiniLM y MPNet sobre los mismos 217 chunks.

10.2. Tamaño de la base vectorial

Las bases de 50, 100, 150 y 217 vectores fueron anidadas y conservaron 11 chunks obligatorios con evidencia. Los restantes fueron distractores elegidos con semilla 42.

Cuadro 8: Efecto de distractores con MPNet y Top-10.

Vectores	Distractores	Recall@10	Accuracy	Consultas (s)
50	39	70 %	50 %	1.408
100	89	70 %	60 %	1.410
150	139	60 %	60 %	1.403
217	206	60 %	60 %	1.412




Figura 5: Recall@10 según el tamaño controlado de la base.

La caída de Recall al agregar distractores no se debió a eliminar conocimiento: la evidencia permaneció indexada, pero perdió posiciones. El tiempo fue casi constante porque BETO procesó como máximo diez chunks en todos los tamaños.

11. RAG monodocumento final

Esta configuración es la conclusión del experimento obligatorio. No se recalcularon sus diez preguntas sobre el corpus ampliado ni se substituyó el PDF por un documento concatenado.

Cuadro 9: Configuración final del laboratorio obligatorio.

Componente	Selección
Documento	Reglamento académico-administrativo de la UES
Modelo QA	BETO-SQAC (MMG)
Embeddings	MPNet multilingüe
Chunk / overlap	800 / 0 caracteres
Índice	FAISS <code>IndexFlatIP</code>
Base	217 vectores de 768 dimensiones
Recuperación	Top-10; Recall@10 de 60 %
Resultado	6/10; QA Accuracy de 60 %

12. Extensión RAG multidocumento

12.1. Diseño

La extensión mantiene BETO-SQAC, MPNet, 800/0, `IndexFlatIP` y Top-10. La base crece a 765 vectores, y la procedencia se convierte en variable experimental. MPNet generó los embeddings en 6.147 s sobre CUDA y la matriz `float32` ocupó 2.24 MiB.

12.2. Resultados de recuperación

Cuadro 10: Recuperación multidocumento por nivel y K.

Métrica	K=1	K=3	K=5	K=10
Document Recall	68.75 %	87.50 %	93.75 %	93.75 %
Chunk Recall	25.00 %	31.25 %	43.75 %	56.25 %

Document Accuracy@1 fue 68.75 %; MRR documental, 0.7833; y MRR de chunk, 0.31875. Las Figuras 6 y 7 muestran la brecha entre localizar un PDF relacionado y recuperar la evidencia exacta.

12.3. Respuesta y abstención

BETO-SQAC respondió correctamente 4 de 16 preguntas respondibles (25 %) y 4 de 18 en total (22.22 %). Ninguna de las dos preguntas sin evidencia produjo abstención; los spans fueron `sta` y `***`.

El comportamiento principal es una pérdida encadenada:




Figura 6: Document Recall@K de la extensión multidocumento.




Figura 7: Chunk Recall@K: recuperación de página y evidencia anotadas.

**93.75 % Document Recall@10 $\longrightarrow$ 56.25 % Chunk Recall@10 $\longrightarrow$
25 % QA Accuracy**

El sistema identifica casi siempre el documento relevante, pero eso no garantiza el fragmento exacto. Después existe una pérdida adicional en QA. Este resultado no se oculta ni se ajusta con nuevas etiquetas.

13. Análisis de errores

13.1. Taxonomía

La extensión usa categorías mutuamente excluyentes:

- **Tipo A:** documento del candidato QA incorrecto.
- **Tipo B:** documento correcto, pero chunk ganador incorrecto.
- **Tipo C:** evidencia recuperada y QA incorrecto.
- **Tipo D:** respuesta parcialmente correcta.
- **Tipo E:** pregunta sin respuesta.

Cuadro 11: Errores observados en la extensión.

Categoría	Casos
A. Documento incorrecto	6
B. Documento correcto, chunk incorrecto	6
C. Recuperación correcta, QA incorrecto	1
D. Respuesta parcial	0
E. Pregunta sin respuesta	2
Sin error integral	3

Un caso informativo produjo el texto correcto una vez al mes, pero desde la Ley Orgánica y no desde el documento esperado. Sin metadata, ese falso positivo documental habría sido contado como éxito integral. Los 18 registros, incluidos los casos sin error, están en `results/rag_multidocumento_errores.csv`.

Cuadro 12: Comparación descriptiva de los dos experimentos.

Característica	Monodocumento	Multidocumento
Documentos	1	9
Páginas	62	199
Chunks	217	765
Recall@10 de evidencia	60 %	56.25 %
QA Accuracy responsable	60 %	25 %
Selección documental	No aplica	Sí
Preguntas	10	16 respondibles + 2 sin respuesta

14. Discusión

14.1. Monodocumento frente a multidocumento

Las métricas no deben compararse como si provinieran del mismo dataset. La extensión usa preguntas nuevas, fuentes relacionadas y ambigüedad documental. La Figura 8 es descriptiva: muestra el coste experimental de añadir fuentes, no una comparación pareada.




Figura 8: Comparación descriptiva; los conjuntos de preguntas son distintos.

14.2. Decisiones técnicas

- **BETO-SQAC**: fue el único extractor con 15/15 en la comparación controlada.

- **MPNet**: mejoró Recall@10 y Accuracy de 40 % a 60 % frente a MiniLM bajo condiciones fijas.
- **FAISS**: permitió búsqueda exacta e interpretable a esta escala.
- **800/0**: empató en aciertos con menos chunks y menor coste entre las variantes de cuatro respuestas correctas.
- **Top-10**: fue el único K probado que alcanzó 4/10 con MiniLM.

Estas razones se basan en resultados ejecutados y no en ventajas inventadas a posteriori.

15. Limitaciones

- Diez preguntas finales en el experimento obligatorio y dieciocho en la extensión; cada caso representa varios puntos porcentuales.
- Una medición temporal por configuración y hardware diferente entre algunas fases históricas.
- Chunking fijo por caracteres, incapaz de integrar evidencia repartida entre ventanas.
- Dos modelos de embeddings, un índice exacto y ausencia de reranking.
- Umbral de abstención no calibrado para el dominio.
- Dependencias y revisiones de checkpoints no fijadas con certeza durante las ejecuciones originales.
- Corpus institucional de un solo dominio; no se evaluaron PDF escaneados ni colecciones de gran escala.

16. Trabajo futuro

Las extensiones no implementadas incluyen reranking; búsqueda híbrida con BM25; chunking por artículo u overlap adaptativo; unión de chunks adyacentes; filtros por metadata; y calibración de abstención. También quedan para otro estudio la evaluación humana, más preguntas y mediciones repetidas sobre el mismo hardware. Son nuevos experimentos, no resultados actuales.

17. Reproducibilidad

El notebook canónico conserva 273 celdas: 129 de código y 144 Markdown. Todas tienen `execution_count`, no existen salidas de error, tracebacks ni celdas vacías. El notebook histórico se conserva únicamente como antecedente.

La ejecución ligera desde la raíz es:

```
python -m venv .venv
source .venv/bin/activate
python -m pip install -r requirements.txt
pytest -q
python -m unittest
python scripts/validar_entrega.py
python -m compileall src
```

La reproducción completa mediante *Run All* descarga modelos y repite experimentos pesados. Para revisar la entrega no es necesaria: los CSV, la metadata, el índice, los gráficos y las salidas del notebook ya están conservados. La ejecución multidocumento registró Python 3.12.3, PyTorch 2.12.1+cu130, CUDA y semilla 42. No se creó un lock artificial porque no se conocen con certeza todas las versiones originales.

La jerarquía de evidencia es: salidas finales del notebook; CSV específico del experimento; código de apoyo; documentación narrativa. La auditoría automática recalcula conteos y comprueba rutas sin ejecutar modelos.

18. Conclusiones

1. BETO-SQAC fue el mejor extractor de los tres evaluados y obtuvo 15/15 en la comparación controlada.
2. La configuración 800/0 ofreció el mejor compromiso del barrido de chunking; el overlap no produjo una mejora uniforme.
3. Top-10 mejoró la cobertura frente a K menores, a costa de más inferencias.
4. MPNet elevó Recall@10 y Accuracy monodocumento a 60 %.
5. FAISS redujo de 2 170 a 100 las inferencias QA del contraste histórico.
6. El score QA no sustituyó la evaluación: el baseline obtuvo 0.942767 de score medio con solo 40 % de Accuracy.
7. En el corpus multidocumento, 93.75 % de Document Recall@10 cayó a 56.25 % de Chunk Recall@10 y 25 % de QA Accuracy.

8. La metadata documental fue necesaria para detectar respuestas textualmente correctas obtenidas desde una fuente equivocada.
9. Las dos preguntas sin respuesta evidenciaron que el extractor requiere una regla de abstención externa y calibrada.
10. Los resultados negativos se conservan como hallazgo experimental y no se modificaron para mejorar las métricas.

Referencias

Referencias

- [1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser e I. Polosukhin. “Attention Is All You Need”. *Advances in Neural Information Processing Systems 30*, 2017. <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>.
- [2] J. Devlin, M.-W. Chang, K. Lee y K. Toutanova. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. *NAACL-HLT*, pp. 4171–4186, 2019. DOI: [10.18653/v1/N19-1423](https://doi.org/10.18653/v1/N19-1423).
- [3] J. Cañete, G. Chaperon, R. Fuentes, J.-H. Ho, H. Kang y J. Pérez. “Spanish Pre-Trained BERT Model and Evaluation Data”. *Practical ML for Developing Countries Workshop, ICLR*, 2020. https://pml4dc.github.io/iclr2020/program/pml4dc_10.html.
- [4] N. Reimers e I. Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. *EMNLP-IJCNLP*, pp. 3982–3992, 2019. DOI: [10.18653/v1/D19-1410](https://doi.org/10.18653/v1/D19-1410).
- [5] K. Song, X. Tan, T. Qin, J. Lu y T.-Y. Liu. “MPNet: Masked and Permuted Pre-training for Language Understanding”. *Advances in Neural Information Processing Systems 33*, 2020. <https://proceedings.neurips.cc/paper/2020/hash/c3a690be93aa602ee2dc0ccab5b7b67e-Abstract.html>.
- [6] J. Johnson, M. Douze y H. Jégou. “Billion-scale similarity search with GPUs”. *IEEE Transactions on Big Data*, 7(3):535–547, 2019. <https://arxiv.org/abs/1702.08734>.
- [7] P. Lewis et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. *Advances in Neural Information Processing Systems 33*, 2020. <https://proceedings.neurips.cc/paper/2020/hash/6b493230-Abstract.html>.
- [8] Hugging Face. “Question answering”. Documentación oficial de Transformers. https://huggingface.co/docs/transformers/tasks/question_answering.
- [9] MMG. “bert-base-spanish-wwm-cased-finetuned-sqac”. Ficha del checkpoint. <https://huggingface.co/MMG/bert-base-spanish-wwm-cased-finetuned-sqac>.
- [10] Sentence Transformers. “paraphrase-multilingual-mpnet-base-v2”. Ficha del modelo. Ficha oficial en Hugging Face.
- [11] Artifex Software. “PyMuPDF: The Basics”. Documentación oficial. <https://pymupdf.readthedocs.io/en/latest/the-basics.html>.
- [12] Universidad de El Salvador. *Reglamento de la Gestión Académico-Administrativa de la Universidad de El Salvador*. Ciudad Universitaria, 2013, con modificaciones consignadas hasta 2017. Copia institucional en [data/documento_fuente.pdf](#).

A. Trazabilidad de artefactos

Cuadro 13: Relación entre entregables y evidencia.

Artefacto	Evidencia
LaboratorioML.ipynb	Configuración, código, salidas, tablas, gráficos y evolución experimental.
results/resultados_qa.csv	Comparación controlada final y resúmenes de chunking, MiniLM, MPNet y tamaño.
results/comparacion_modelos.csv	Benchmark histórico de 60 inferencias, conservado como evidencia separada.
rag_multidocumento_metricas.csv	Recall, MRR, QA Accuracy y abstención.
rag_multidocumento_metadata.jsonl	765 chunks con documento, página, identificadores, posición y texto.
rag_multidocumento_errores.csv	Clasificación completa de 18 preguntas.
src/funciones_qa.py	Normalización, chunking, validación, recuperación y métricas.
scripts/validar_entrega.py	Auditoría ligera del notebook, corpus, métricas, metadata y figuras.

B. Resumen de preguntas documentales

Cuadro 14: Preguntas del experimento monodocumento.

#	Pregunta	Respuesta esperada
1	¿Con qué periodicidad sesiona ordinariamente el Consejo Académico?	una vez al mes
2	¿Cuál es el máximo de veces que un estudiante puede cambiar de carrera?	dos veces
3	¿Cuánto dura ordinariamente la calidad de egresado?	tres años académicos
4	¿Qué unidades integran internamente la Secretaría de Asuntos Académicos?	tres unidades anotadas
5	¿Qué prueba se aplica después del curso de refuerzo académico en línea?	prueba de conocimiento general
6	¿A qué proceso se somete al estudiante con CUM menor a siete?	asesoría presencial o en línea

#	Pregunta	Respuesta esperada
7	¿Quién nombra a los miembros del Tribunal Calificador?	Junta Directiva
8	¿Según qué reglamento se tramita el ingreso a posgrado?	reglamento de estudios de posgrado
9	¿Cuándo entra en vigencia el Reglamento?	ocho días después de su publicación
10	¿Por cuánto tiempo se amplía la calidad de egresado en el caso anotado?	un año académico más

C. Validación final

Cuadro 15: Estado de los componentes de entrega.

Componente	Estado
Laboratorio obligatorio y QA extractivo	Completo
Embeddings, FAISS y evaluación Top-K	Completo
RAG monodocumento	Completo
RAG multidocumento y análisis de errores	Completo
Notebook canónico ejecutado sin errores	Verificado
Tests ligeros	Verificados
README, documentación y trazabilidad	Completo
Informe LaTeX y PDF	Completo